




Mana Lite: Visión Clínica en el Borde


Arquitectura determinista para IA de percepción en entornos de misión crítica.

La simplicidad como requisito para el determinismo clínico

Diagnóstico de Ingeniería	Mana OS	Mana Lite
Arquitectura:	Multi-proceso, Grafo Acíclico Dirigido (DAG)	Binario estático único
Comunicación:	Memoria compartida IPC / Zenoh	Cero dependencias externas
Ejecución:	Paralelismo total, hilos asíncronos	Superloop síncrono, un solo hilo principal
Enfoque:	Escalabilidad multi-cámara distribuida	Cámara única en hardware de borde (Jetson/ARM)

Insight: En la evaluación clínica de borde, un fallo de red o una condición de carrera asíncrona es inaceptable. El determinismo estricto supera a la complejidad distribuida.

El Motor PLC: Ejecución síncrona predecible




// Por qué no Async:

El código asíncrono intercala tareas impredeciblemente.

En un bucle síncrono, las mismas entradas de red y píxeles garantizan exactamente la misma salida clínica.

Cero hilos de fondo.
Cero race conditions.

Ingesta Inteligente: Destilación agresiva en la capa NAL




El Problema: 30 fps queman térmicamente las GPUs de borde. Los eventos clínicos suceden en segundos, no milisegundos.

La Solución: Identificación de unidades NAL tipo IDR directamente en los paquetes de red sin decodificar píxeles.

Reducción del 97% en costo de cómputo de decodificación.

Inferencia en Cascada: Compuertas semánticas y recortes dinámicos




Padre (detect-fast): Escanea 1080p.
Condición: ¿Persona detectada?

Hijo (face-yolo): Crop
dinámico exacto de 320x320
centrado en la mitad superior.

Nota Arquitectónica: El ROI dinámico del modelo hijo puede exceder deliberadamente los límites estáticos del padre, garantizando la captura de rostros en los bordes extremos del lente, reduciendo la latencia térmica general.

Consolidación de Evidencia: Una entidad unificada por cuadro



Regla Base:

El bounding box principal define a la entidad.

Enriquecimientos:

El consolidador asocia salidas secundarias espacialmente. Una cara se asocia a una persona solo si su área está contenida dentro del padre.


Insight:

NMS (Non-Maximum Suppression) elimina candidatos solapados del mismo tipo, pero la Consolidación Semántica integra modelos distintos sin duplicar a la persona en la telemetría.

Memoria e Identidad:

Tracking SORT calibrado para la clínica

El Algoritmo



Filtro Kalman 7D: Asume velocidad constante. Ideal para movimientos humanos clínicos lentos y predecibles.

Asignación Húngara: Emparejamiento por IoU. Costo infinito estricto para clases distintas (un track de cama jamás se asocia a una cara).

Tuning Clínico

max_age = 20

Tolerancia extrema a la oclusión. Si un paciente es tapado por un médico durante 40 segundos, el sistema preserva la identidad.

min_hits = 2

Confirmación agresiva temprana para no retrasar alertas críticas de abandono de cama.

iou_threshold = 0.2

Ajustado para mantener el rastro de pacientes a gran distancia focal.

Lógica Espacial y Zonas: Filtrando el caos visual




El Problema:

Las detecciones de IA fluctúan por oclusión parcial, perdiendo el cuadro por microsegundos. Esto causa falsas alertas de abandono de cama.

La Solución PLC:

Una zona de hospital (ej. zones.bed) no declara el evento semántico Vacated hasta que el bounding box del paciente ha estado ausente por X milisegundos de forma ininterrumpida.

Conciencia 3D: Reglas de profundidad y mapeo métrico



Mapas Locales:

La estimación monocular de profundidad se recorta estrictamente al ROI, salvando 4.5x de RAM vs frame completo. La matriz de tensores permanece local.

Estadística Robusta:


Uso de medianas y percentiles (P10/P90) dentro del área del paciente para evitar que un solo píxel ruidoso dispare una alerta de proximidad.

Calibración:

$$\text{scene_m} = \text{model_val} * (\text{ref_scene_m} / \text{ref_model_m})$$

Escaneo lineal de unidades relativas del tensor a metros físicos reales referenciando la escena.

Cardinalidad de la Habitación: Filtros de Presencia



Debounce Temporal


Las observaciones primarias pasan por un filtro de ticks. Los vacíos momentáneos retienen (hold) la última observación válida antes de que el cerebro clínico actúe.

Timers Monótonos

Transicionar a Multiple (ej. enfermera entra) requiere que la evidencia múltiple persista por `multiple_confirm_ms`.

Insight: La política de proteger el rastro del paciente está intencionalmente separada de la política de contar visitantes de forma estable.

El Cerebro Clínico: Evaluación FSM Determinista



Orden Estricto

Las reglas se evalúan en el orden exacto del TOML. Las mismas entradas producen siempre el mismo estado semántico.

Wildcards Prioritarios

Reglas de salud global (ej. * -> blind por caída de red RTSP) sobrescriben la lógica estándar para asegurar la recuperación de errores.

El Face Latch

Memoria booleana interna. El FSM recuerda si la persona visualmente perdida estaba previamente en la cama, diferenciando un abandono real de un error de oclusión.

Orquestación Desacoplada mediante Blueprints TOML



`blueprint.toml` (DevOps)
El orquestador. Define qué modelos corren y las reglas de cascada (`same_frame`, `requires_exact_count`).



`models.toml` (Ingeniero ML)
Catálogo inmutable de modelos ONNX y umbrales base.



`zones.toml` (Facility Manager)
Coordenadas espaciales físicas (cama, puerta).



`fsm.toml` (Ingeniero Clínico)
Reglas de transición, tiempos de histéresis y estado.

Flexibilidad de Despliegue: Cambiar de un perfil ligero de calibración a monitoreo clínico intensivo 24/7 requiere modificar una sola línea:
`blueprint_file = 'detect-room-face'`.

Observabilidad Estructurada: JSON Lines y Ghost Mode

```
{
  "type": "fsm", "timestamp": "2023-10-27T10:00:01.123Z",
  "state": "in_bed",
  "data": {
    "occupant_id": 1,
    "confidence": 0.98
  },
  "source": "superloop"
}
{
  "type": "fsm", "timestamp": "2023-10-27T10:00:01.245Z",
  "state": "in_bed",
  "data": {
    "occupant_id": 1,
    "confidence": 0.98
  },
  "source": "superloop"
}
{
  "type": "fsm", "timestamp": "2023-10-27T10:00:01.367Z",
  "state": "in_bed",
  "data": {
    "occupant_id": 1,
    "confidence": 0.99
  },
  "source": "superloop"
}
```

EVENT SCHEMA

```
type: fsm
timestamp: ISO 8601
state: current_state
data: (variable payload)
source: module_name
```

Contrato de Salida (stdout atómico)


1 Evento Semántico = 1 Línea de texto JSON (JSONL). Directamente consumible por jq, Python o Logstash.

Separación estricta entre telemetría operativa (stderr) y clínica (stdout). Cero dependencias IPC.

El Ghost Mode

Durante los ciclos donde no llega un nuevo I-Frame, el Superloop sigue evaluando el FSM asumiendo las detecciones fantasma previas, garantizando un flujo constante de latidos de estado (Heartbeats) sin sobrecargar la GPU.

Síntesis: Un Pipeline Clínico Inquebrantable



Mana Lite destila el caos algorítmico de los píxeles crudos en decisiones clínicas absolutas, ejecutándose implacablemente dentro de una caja del tamaño de un enrutador.